Informe de análisis: campañas de marketing directo de un banco Portugués

Proyecto de Análisis de Datos con Python y Pandas.
Carolina Gómez Bracho

1. Objetivo y contexto

Se ha trabajado con dos fuentes de datos:

- **Campañas (bank-additional.csv)** 43.000 filas x 24 columnas. Datos del cliente, de la llamada, de campañas previas y del contexto económico.
- **Clientes (customer-details.xlsx)**: 3 hojas (una por año de alta) con las mismas 7 columnas: ingreso anual, hijos, adolescentes, fecha de alta, visitas web mensuales e ID.

Ambas se unieron por el identificador del cliente: **42.911 ID en común.**

Preguntas del análisis

1. ¿Qué perfiles y circunstancias se asocian a una mayor contratación?
2. ¿Aportan las características demográficas del segundo dataset (ingreso, hijos, visitas web) a explicar la contratación?

2. Transformación y limpieza de los datos.

- Columna residual 'Unamed: 0' en ambos datasets, eliminada no aporta informacion
- 'cons.price.idx', 'cons.conf.idx', 'euribor3m' y 'nr.employed' usan coma decimal (por ejemplo, 93,994) y se leían como texto.
- Tras esa recarga 'age', 'emp.var.rate', 'default', 'housing', 'loan', 'latitude' y 'longitude' (que usan punto) quedaron como texto. Convertidas a numérico con pd.to_numeric; 'default', 'housing' y 'loan' se mantienen como 1/0 con sus nulos.
- Edades imposibles: el mínimo original era 17 años (menores de edad); el máximo era 98. Las edades <18 o >100 se marcaron como nulas para imputarlas con el resto. Rango final: 18-98.
- Fechas en español (2-agosto-2019): 'to_datetime' las convertía todas a nulo. Se tradujeron los meses con un diccionario y se asignaron a cada cliente por id_ (no por posición). Quedan 248 nulos originales.

- pdays = 999 significa "no contactado antes" (96 % de los casos). Se creó ‘contactado_antes’ (0/1) y se sustituyó 999 por NaN para no distorsionar media y desviación.
- ‘marita’l y ‘poutcome’ en mayúsculas. Unificadas en minúsculas y sin espacios.
- 4 llamadas con ‘duration’ = 0 s. Eliminadas: una llamada de 0 s no es un contacto real.
- Duplicados 0 encontrados (ignorando índice e ID).

Paso	Acción	Filas
Carga	CSV original	43.000
Duplicados	0 encontrados (ignorando índice e ID)	43.000
marital nulo	Filas eliminadas	42.915
Imputación	Sin pérdida de filas	42.915
duration = 0	Eliminadas (una llamada de 0 s no es un contacto real)	42.911

Datos faltantes y decisiones

- Antes de imputar se crearon columnas indicadoras (age_era_nulo, euribor3m_era_nulo, cons.price.idx_era_nulo) para saber qué valores eran estimados.

Columna	Nulos	%	Decisión	Justificación
euribor3m	9.256	21,5 %	Mediana por periodo (nr.employed, emp.var.rate)	Es un indicador de mercado, constante por periodo; imputar por grupo es más preciso que la mediana global
default	8.981	20,9 %	Categoría float	Solo 3 clientes tienen incumplimiento
age	5.120	11,9 %	Mediana por job	Numérica algo sesgada; la profesión explica parte de la edad
education	1.807	4,2 %	Moda por job	Relación fuerte entre profesión y estudios

housing, loan	1.026	2,4 %	float	Faltan en las mismas filas
cons.price.idx	471	1,1 %	Mediana por periodo	Variable macro, igual que euribor3m
job	345	0,8 %	"unknown"	Pocos casos
date	248	0,6 %	Se mantienen como nulos	Solo afecta al análisis temporal
marital	85	0,2 %	Filas eliminadas	Pérdida despreciable

Los nulos corresponden al CSV original de 43.000 filas. En el dataset final (42.911 filas) default tiene 8.969 nulos, housing y loan 1.025 cada una, y pdays 41.328 (los 999 convertidos). En el dataset de clientes no había nulos.

Trazabilidad de filas

Paso	Filas
CSV original	43.000
Duplicados (0 encontrados)	43.000
‘marital’ nulo: filas eliminadas	42.915
Imputación (sin pérdida de filas)	42.915
’duration’ = 0: filas eliminadas	42.911

Unión de datasets

- Las tres hojas se leyeron con ‘sheet_name=None’ y se concatenaron, añadiendo la columna hoja (año de alta). Cada hoja contiene solo fechas de su año.
- No hay ID repetidos en ninguno de los dos datasets.
- ‘merge’ por ID con ‘validate=”one_to_one”’, sin errores.
  Resultado: **42.911 filas x 37 columnas.**
  Los 259 clientes del Excel sin llamada asociada quedan fuera de la unión.

Columnas creadas

‘y_num’(0/1), ‘contactado_antes’, columnas ‘era_nulo’, ‘anio’ y ‘mes’ (de la llamada), ‘hijos_total’ (‘kidhome’ + ‘Teenhome’), tramo_ingreso (cuartiles).

3. Análisis descriptivo

Variables numéricas de campañas

	mean	median	std	min	max	skew
age	39.81	38.00	9.96	18.00	98.00	0.88
duration	257.65	179.00	258.60	1.00	4918.00	3.32
campaign	2.57	2.00	2.77	1.00	56.00	4.78
previous	0.17	0.00	0.50	0.00	7.00	3.84
emp.var.rate	0.08	1.10	1.57	-3.40	1.40	-0.72
cons.price.idx	93.57	93.75	0.58	92.20	94.77	-0.23
cons.conf.idx	-40.51	-41.80	4.64	-50.80	-26.90	0.31
euribor3m	3.62	4.86	1.74	0.63	5.04	-0.70
nr.employed	5166.87	5191.00	72.42	4963.60	5228.10	-1.04

Lectura:

- ‘duration’ y ‘campaign’ tienen cola larga a la derecha: la media queda por encima de la mediana y la asimetría es mayor que 3. Hay llamadas de hasta 82 minutos (4.918 s) y clientes contactados hasta 56 veces.
- ‘previous’ tiene mediana 0 y asimetría de 3,84: la mayoría de los clientes no había sido contactado antes.
- ‘cons.price.idx’ (asimetría -0,23) y ‘cons.conf.idx’ (0,31) son casi simétricas, con la media cercana a la mediana. ‘age’ presenta una asimetría moderada a la derecha (0,88), con una cola de clientes de mayor edad.
- ‘emp.var.rate’ , ‘euribor3m’ y nr.employed tienen la media por debajo de la mediana (por ejemplo, 0,08 frente a 1,10 en emp.var.rate) y una asimetría negativa. No se debe a outliers, sino a que los datos se agrupan en periodos económicos distintos (distribución bimodal).

Variables categóricas

- **Profesión** ‘admin.’ 25,3%, ‘blue-collar’ 22,5%, ‘technician’ 16,3%, ‘services’ 9,7%, ‘management’ 7,1%, ‘retired’ 4,2%.
- **Estado Civil** ‘casado’ 60,6%, ‘soltero’ 28,2%, ‘divorciado’ 11,2%.
- **Educación** ‘university.degree’ 31%, ‘high.school’ 23,9%, ‘basic.9y’ 15,8%.

- **Contacto:** cellular 63,7 %, telephone 36,3 %.
- **Resultado de campaña previa** ‘nonexistent’ 86,3%, ‘failure’ 10,4%, ‘success’ 3,3%.
- **Préstamos (sobre valores conocidos)**: hipoteca (housing) 53,6 %, otro préstamo (loan) 15,6 %. default es prácticamente constante (3 casos con 1).

Outliers

Variable	Outliers (IQR)	%	Decisión
duration	3.090	7,2%	Mantener: llamadas largas reales
campaign	2.493	5,8%	Mantener: clientes contactados muchas veces
age	573	1,3%	Mantener: edades de 70-98 años plausibles
previous	5878	13,7%	No aplicable: Q1 = Q3 = 0, el IQR vale 0 y cualquier valor > 0 sale marcado.
Income, NumWebVisitsMonth (clientes)	0	0%	NA

Los outliers son datos reales y no errores, por lo que se conservaron. En los gráficos se usó escala logarítmica para duration. ç

Dataset de clientes

	Income	Kidhome	Teenhome	NumWebVisitsMonth
count	43170.000000	43170.000000	43170.000000	43170.000000
mean	93227.389622	1.004749	0.998633	16.591290
std	50498.181989	0.815996	0.816008	9.241769
min	5841.000000	0.000000	0.000000	1.000000
25%	49608.000000	0.000000	0.000000	9.000000
50%	93009.500000	1.000000	1.000000	17.000000
75%	136740.500000	2.000000	2.000000	25.000000
max	180802.000000	2.000000	2.000000	32.000000

Desviaciones estándar: 'Income' 50.498; 'Kidhome' y 'Teenhome' 0,82; 'NumWebVisitsMonth' 9,24. Con media (aprox igual a) mediana y cuartiles equidistantes, las distribuciones son **casi uniformes.**

Coherencia temporal

Las altas son de 2012-2014 y las llamadas de 2015-2019. Ninguna llamada es anterior al alta: la diferencia mínima es de 8 días, la mediana de 1.515 días (aprox 4,1 años) y el máximo 2.921 (aprox 8 años) date (llamada) y 'Dt_Customer' (alta) son variables distintas y se mantienen separadas.

Correlaciones con la contratación (y_num)

```
y_num             1.00
duration          0.40
previous          0.23
cons.conf.idx     0.06
age               0.03
campaign         -0.07
cons.price.idx   -0.14
emp.var.rate     -0.30
euribor3m        -0.31
nr.employed      -0.36
Name: y_num, dtype: float64
```

Las variables macroeconómicas están muy correlacionadas entre sí ('emp.var.rate-euribor3n' 0,97); 'euribor3n-nr.employed' 0,95; 'emp.rate-nr.employed' 0,91), por lo que son esencialmente un único factor: el contexto económico (multicolinealidad)

4. Visualizaciones e interpretación

Campañas

Gráfico 1 Distribución de la variable objetivo Hay un desbalance fuerte: unos 38.000 “no” frente a unos 5.000 “yes” (11,3 % de conversión). Menciónalo, porque si luego haces un modelo, la exactitud (accuracy) engaña: predecir siempre “no” ya daría ~89 %.

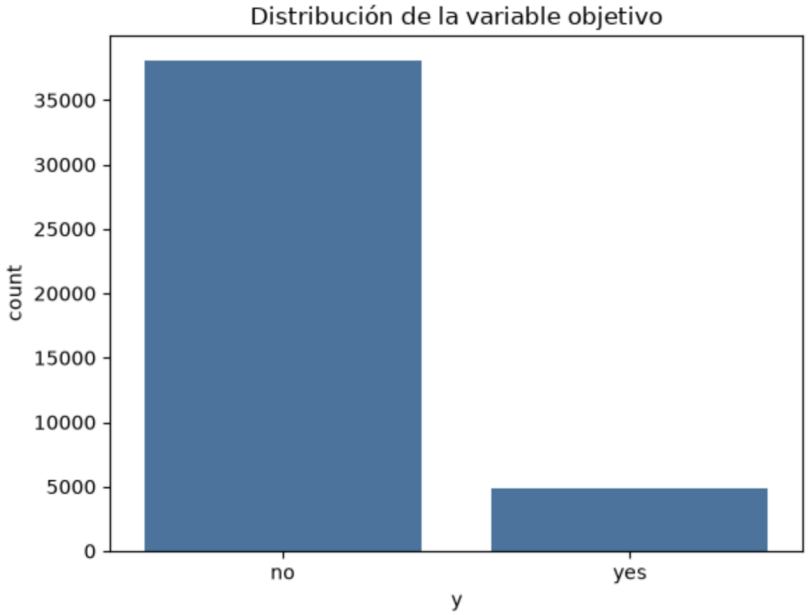


Gráfico 2 Duración de las llamadas, escala logarítmica En escala logarítmica la distribución es casi simétrica y se centra en 150-200 segundos. Eso justifica conservar los outliers: siguen una distribución log-normal. Hay una pequeña cola de llamadas muy cortas (<20s).

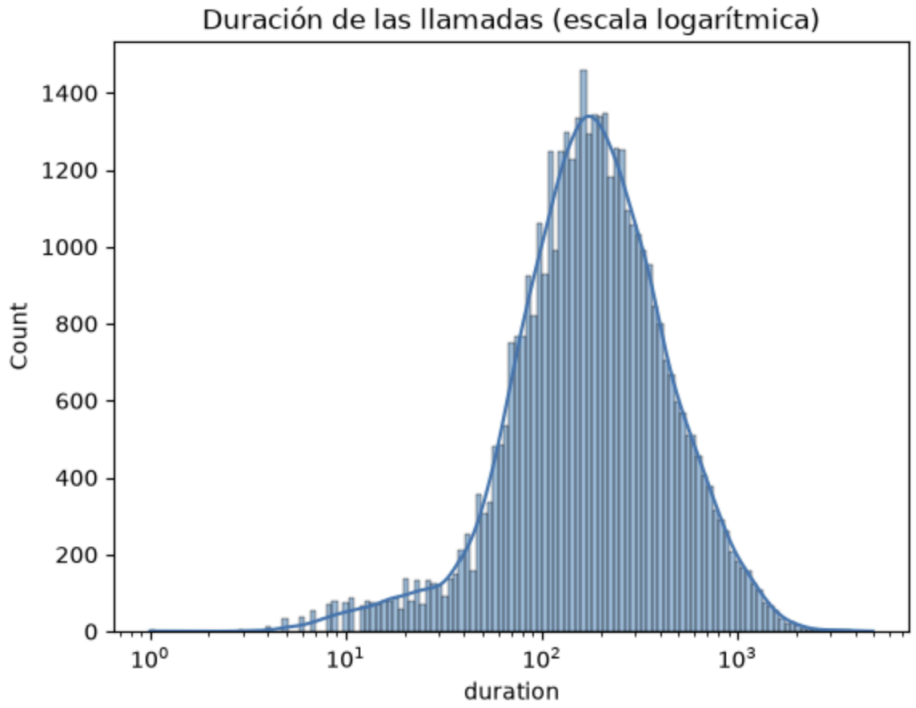


Gráfico 3 Conversión por profesión 'student' (31,4%, n = 902) y 'retired' (25,2%, n=1.784) superan más del doble de la tasa global; 'unemployed' (14,5%) y 'admin.'(13%) quedan por encima. 'blue_collar' (6,9 %, n=9.639) y 'services' (8,1%) están por debajo. La línea roja marca la tasa global (11,3%)

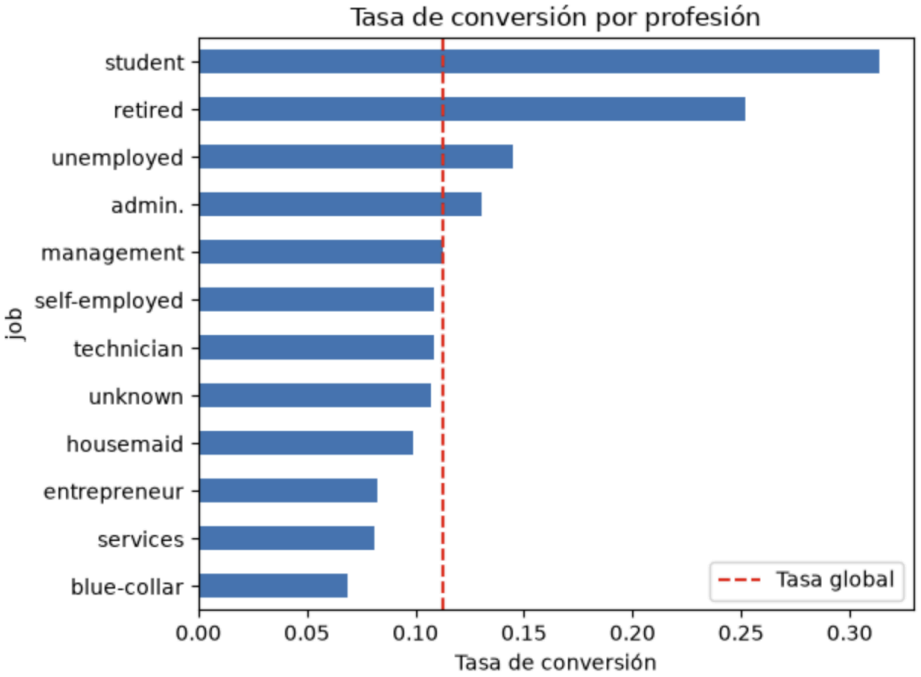


Gráfico 4 Duración según contratación Quienes contratan hablan más: mediana aprox. 450 s frente a aprox. 160 s, y casi todos los 'sí' duran más de 60 s. La duración solo se conoce después de la llamada.

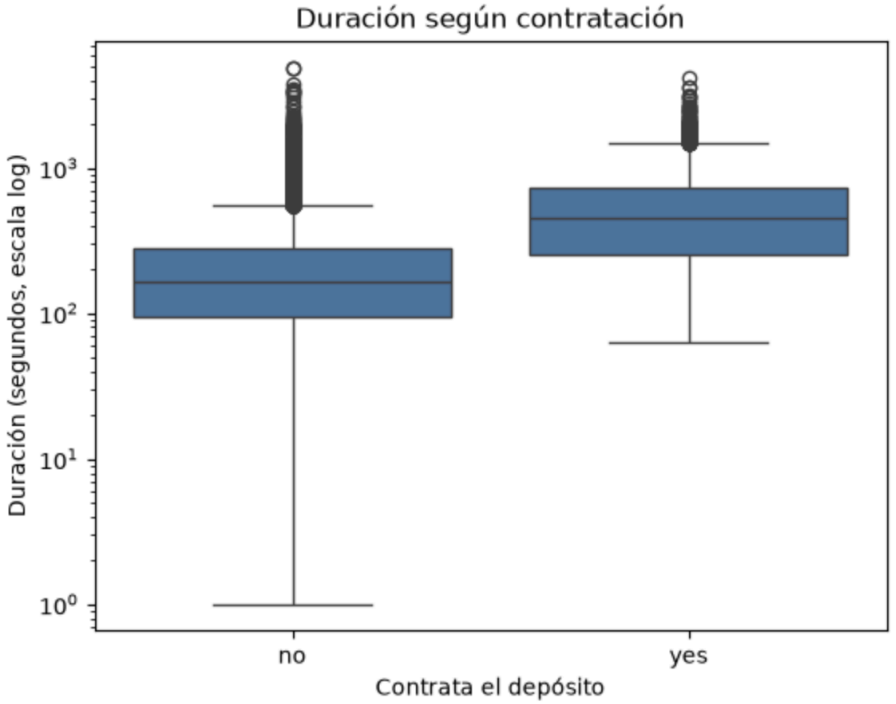


Gráfico 5 Matriz de correlaciones Muestra el bloque macroeconómico (r>0,9) y que 'duration' (+0,40) y 'nr.employed' (-0,36) son las variables más ligadas a la contratación. 'previous' se relaciona con el contexto económico (r entre -0,42, y -0,50.

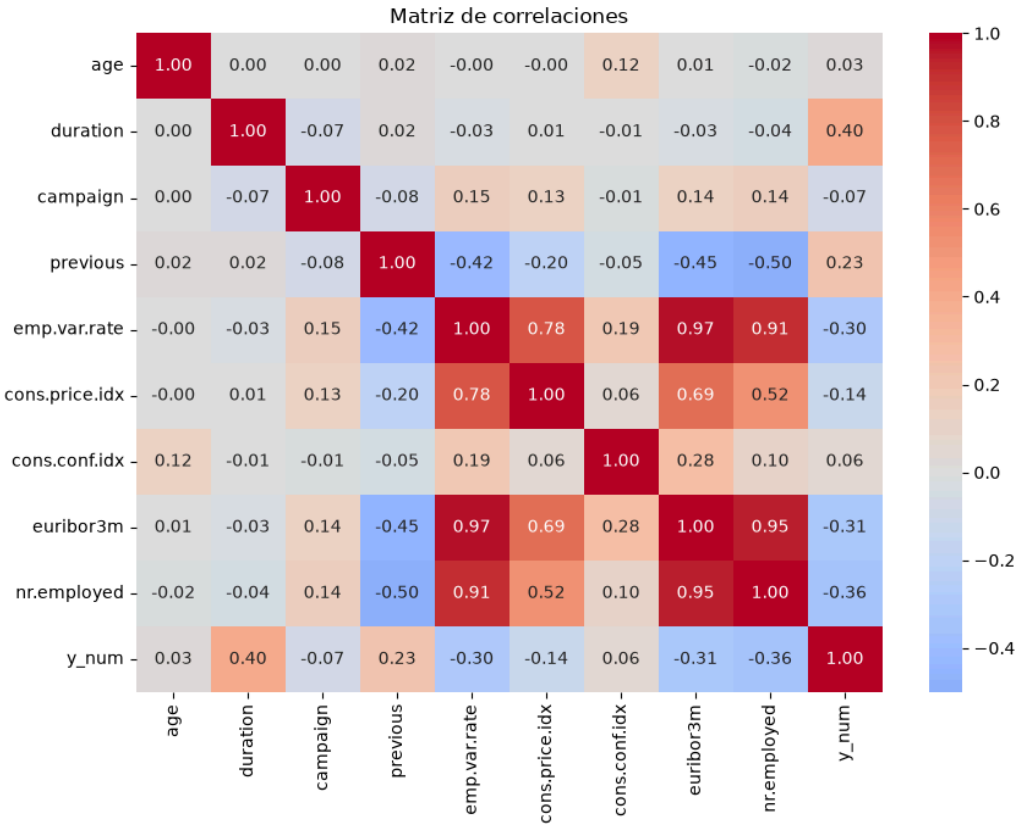
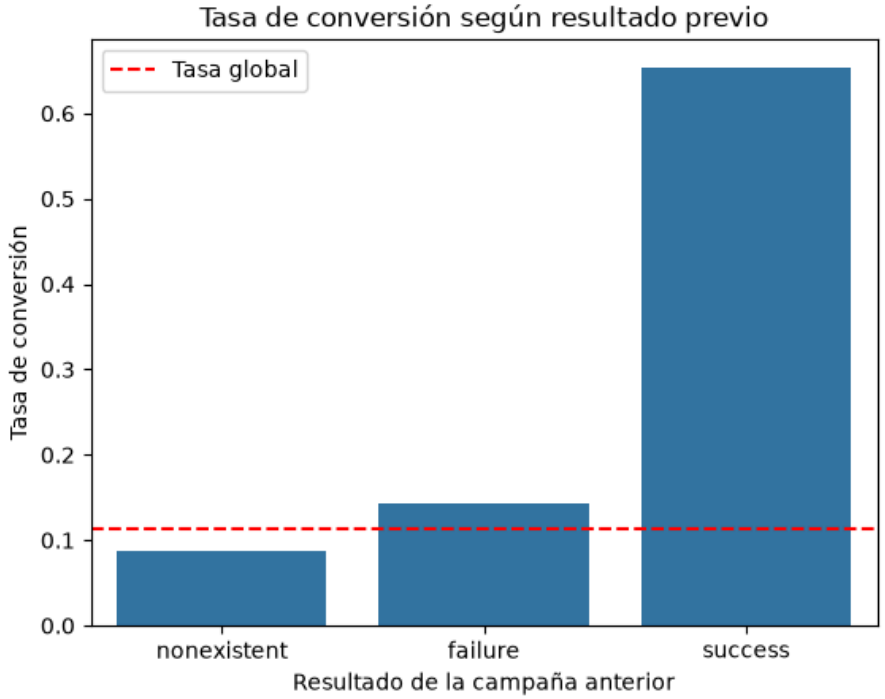


Gráfico 6 Conversión según resultado previo 'success' convierte un 65,3 % (n = 1.431) frente a 14,2 % de 'failure' y 8,8% de 'nonexistent':

unas 7 veces más que sin contacto previo. Incluso ‘failure’ supera a ‘nonexistent’



Clientes y cruce con campañas

Gráfico 7 Distribución del ingreso anual Histograma casi plano entre 5.841 y 180.802, con aprox 1.400-1.500 clientes por intervalo. Sin asimetría ni outliers, lo cual es poco habitual en ingresos reales. El ingreso anual se distribuye de forma uniforme entre 5.841 y 180.802 (media ≈ mediana ≈ 93.000), sin asimetría ni outliers. Este patrón es poco habitual en ingresos reales y sugiere datos sintéticos, lo que se señala como limitación.

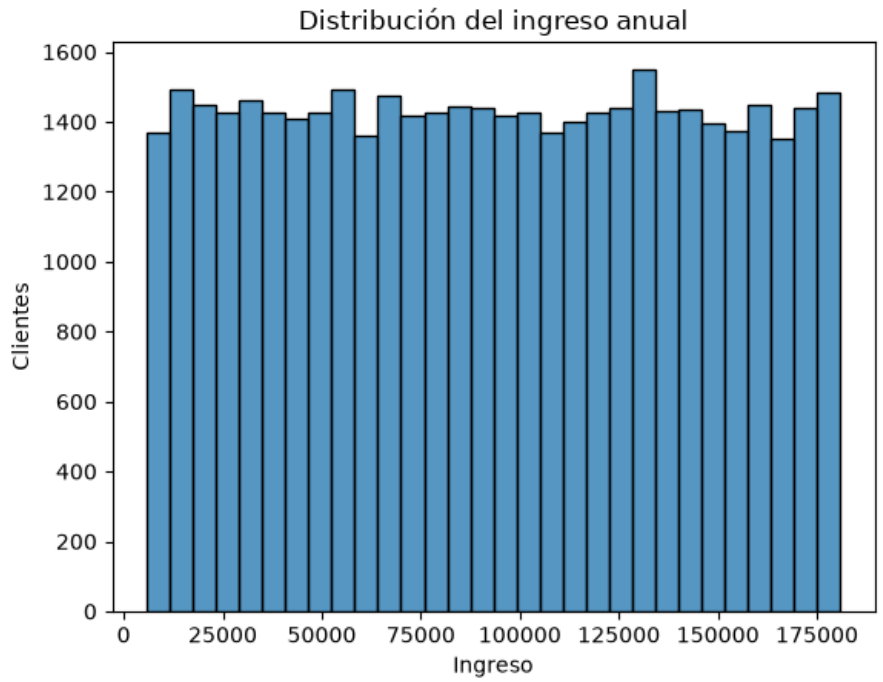


Gráfico 8 Conversión por tramo de ingreso

tramo_ingreso	mean	count
bajo	0.113	10728
medio-bajo	0.115	10729
medio-alto	0.114	10726
alto	0.108	10728

Las cuatro barras quedan pegadas a la tasa global y no hay tendencia progresiva. La conversión no varía de forma relevante según el ingreso (10,8 %-11,5 %). El test chi-cuadrado (p = 0,447) confirma que las diferencias son atribuibles al azar.

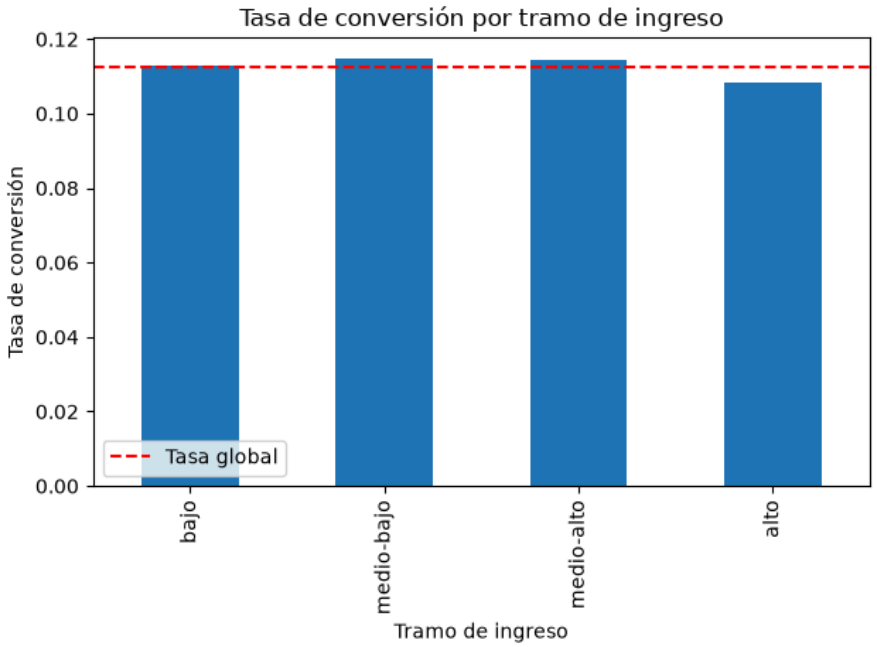


Gráfico 9 Conversión por número de hijos

Entre 10,8% y 11,8% sin patrón (0 hijos: 11,8%; 1: 10,8%; 2: 11,5 %; 3: 11%; 4: 11,5%). La composición familiar no condiciona la contratación: las tasas se mantienen en torno a la media global sin tendencia (p = 0,266).

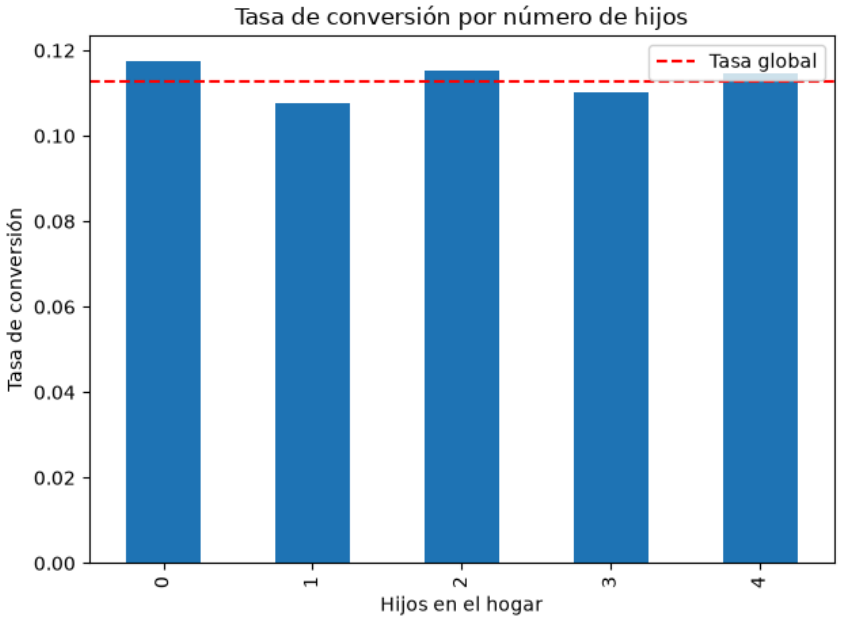


Gráfico 10 Clientes por año de alta

La base de clientes procede de tres cohortes de alta: 2012 (46,6 %), 2013 (20,8 %) y 2014 (32,6 %). La distribución no es uniforme entre años, aunque la fecha de alta no afecta a la conversión.
2012: 20.115 (46,6%); 2013: 8.965 (20,8%); 2014: 14.090 (32,6).
Porcentajes sobre las hojas originales (43.170); en el dataset unido pueden variar mínimamente



Pruebas estadísticas

```
'p-valor: 0.447'
```

```
p-valor hijos: 0.266
```

Variable	Prueba	p-valor	Conclusión
Tramo de ingreso	Chi-cuadrado de independencia	0,447	Sin relación
Hijos en el Hogar	Chi-cuadrado de independencia	0,266	Sin relación

En ambos casos p>0,05, por lo que no se rechaza la independencia: las diferencias observadas se explican por azar. Las correlaciones lineales de 'Income', 'NumWebVisitMonth' y 'hijos_total' con 'y_num' son todas |r| <= 0,01

Tendencia temporal: la conversión por año de la llamada es estable (10,9 % en 2015; 11,7 % en 2016; 11% en 2017; 11,5% en 2018; 11,3% en 2019), con aproximadamente 8.500 clientes por año.

5. Conclusiones y recomendaciones

Conclusiones

1. La tasa global de contratación es del 11,3 %, con fuerte desbalance entre "sí" y "no".
2. El resultado de la campaña previa es el predictor categórico más fuerte: 'success' convierte un 65,3 % frente al 8,8 % de quienes no habían sido contactados.
3. La profesión influye de forma clara: estudiantes (31,4 %) y jubilados (25,2 %) más que duplican la media; 'blue-collar' (6,9 %) y services (8,1 %). El nivel educativo también: 'university.degree' 13,7 % frente a 'basic.9y' 7,6 %.
4. El método de contacto marca diferencia: cellular convierte un 14,7 % frente a un 5,2 % de telephone.
5. El contexto económico condiciona la contratación: con euríbor y empleo altos se contrata menos (r entre -0,30 y -0,36). Las tres variables miden un único factor.
6. Insistir con más llamadas no mejora el resultado ('campaign', r = -0,07).
7. Las llamadas más largas se asocian a más contratación (r = 0,40), pero la duración solo se conoce después de la llamada.
8. Ingreso, hijos y visitas web no explican la contratación ($|r| \leq 0{,}01$; p = 0,447 y p = 0,266), y la conversión es estable entre años de llamada (10,9 %-11,7 %). Descartar variables también es un resultado válido.

Recomendaciones

- Recontactar de forma prioritaria a los clientes con éxito previo.
- Segmentar hacia estudiantes y jubilados, que tienen alta propensión, teniendo en cuenta que son segmentos pequeños en volumen (~6 % de la base).
- Priorizar el contacto por móvil frente al teléfono fijo, comprobando antes que no dependa del periodo de la campaña.
- Evitar segmentar por ingreso o composición familiar, que no discriminan.
- No insistir con muchos contactos al mismo cliente.
- Valorar el momento económico al planificar campañas. 6.

6. Limitaciones

- **Desbalance** de la variable objetivo (11,3 % de "sí").
- **Fuga de datos: ‘**duration’ solo se conoce tras la llamada, por lo que no sirve para decidir a quién llamar ni debe usarse en un modelo predictivo.
- **Grupos pequeños:** ‘illiterate’ (n = 18, conversión del 22 %) no es fiable; student (n = 902) y success (n = 1.431) son minoritarios. No se sacan conclusiones de unknown (n = 336).
- **Valores imputados:** ‘euribor3m’ (21,5 %), ‘age’ (11,9 %) y ‘education’ (4,2 %) se estimaron, lo que reduce algo la variabilidad. default (20,9 % de nulos y solo 3 casos con 1) no se usa para conclusiones.
- **Datos con apariencia sintética:** el ingreso, los hijos y las visitas web tienen distribuciones casi uniformes y sin relación entre sí.
- **Correlación no implica causalidad**, y r ≈ 0 solo descarta relación lineal: una variable con r 'bajo puede influir de forma no lineal (por ejemplo, la edad con r = 0,03 podría influir por tramos, algo que no se ha analizado).